

KoHateMask: 코드스위칭 강건성을 갖춘 한국어 다중 라벨 혐오 표현 탐지 및 마스킹 시스템

1. 서론
 2. 관련 연구
 - 2.1 한국어 혐오 표현 탐지
 - 2.2 다국어 및 교차 언어 접근
 - 2.3 혐오 표현 탐지에서의 코드스위칭
 - 2.4 스펠 탐지 및 근거 추출
 - 2.5 데이터셋 구성 및 라벨 품질
 3. 문제 정형화
 4. 시스템 아키텍처
 - 4.1 KoNorm-v3: 텍스트 정규화 파이프라인
 - 4.2 다중 라벨 분류 모델
 - 4.3 스펠 탐지 모듈
 5. 데이터셋 구성
 - 5.1 학습 데이터
 - 5.2 검증 및 테스트 분할
 6. 실험
 - 6.1 실험 설정
 - 6.2 주요 결과
 - 6.3 학습 곡선
 - 6.4 코드스위칭 강건성
 - 6.5 플랫폼별 도메인 분석
 - 6.6 통계적 유의성
 7. 오류 분석
 - 7.1 오류 분류 체계
 - 7.2 정책 결정 필요 사례
 - 7.3 스코어 프로파일 분석
 - 7.4 잔존 허위 음성 분석
 8. 스펠 탐지 성능
 9. 한계 및 향후 연구
 10. 결론
- 참고 문헌

KoHateMask: 코드스위칭 강건성을 갖춘 한국어 다중 라벨 혐오 표현 탐지 및 마스킹 시스템

요약 — 소셜 미디어 플랫폼에서의 유해 표현 확산은 자동화된 콘텐츠 조정 시스템에 대한 수요를 증대시키고 있다. 기존 한국어 혐오 표현 탐지 연구는 세 가지 핵심 한계를 노출한다: (1) 표면적 욕설, 의도적 공격성, 집단 혐오를 구분하지 않는 단일 라벨 분류; (2) QWERTY 치환, 초성 전사, 공백 삽입 등 우회 전략에 대한 취약성; (3) 이질적 어노테이션 스키마를 가진 다중 소스 학습 시의 비어 노테이션 라벨 허위 역전파. 본 논문에서는 이러한 한계를 극복하는 한국어 혐오 표현 탐지·마스킹 시스템 **KoHateMask**를 제안한다. 핵심 기여는 다음 여섯 가지다. 첫째, 소스별 어노테이션 불완전

성을 손실 함수 수준에서 처리하는 **label-mask 학습 메커니즘**을 도입한다. 둘째, QWERTY→한글 역변환, 초성 전사, 공백 삽입 우회 병합, 변형 철자 정규화를 포함하는 다단계 정규화 파이프라인 **KoNorm-v3**를 구성한다. 셋째, mDeBERTa-v3-base 백본 기반으로 431,786개 한영 댓글을 학습하여 욕설(P)·공격성(T)·혐오(H) 세 라벨에 대해 테스트셋 매크로 F1 0.766 (95% CI: [0.760, 0.773])을 달성한다. 넷째, 4가지 코드스위칭 패턴으로 구성된 합성 스트레스 테스트에서 매크로 F1 0.855를 기록한다. APEACH+HateXplain 외부 평가셋에서 기준 모델 대비 T+H 매크로 F1 0.640 (+23.8%)을 달성하며, 정책 결정이 필요한 탐지 사례와 실제 모델 오류를 구분하는 3계층 오류 분류 체계를 제안한다. 토큰 수준 마스킹 위치를 탐지하는 스펠 탐지 모듈(XLM-RoBERTa-large + CRF)은 스펠 F1 0.554를 달성하며, 크롬 익스텐션 및 안드로이드 앱에 연동된다.

키워드 — 한국어 혐오 표현 탐지; 다중 라벨 분류; 코드스위칭 강건성; 텍스트 정규화; 스펠 탐지; 콘텐츠 조정

1. 서론

온라인 소셜 미디어 플랫폼은 욕설, 공격적 발화, 보호집단을 향한 혐오 표현이 급속히 확산되는 주요 경로가 되었다. 대규모 자동 탐지 시스템의 필요성이 커지는 가운데, 한국어는 자동화된 탐지를 특히 어렵게 만드는 언어적 특성을 지닌다. 사용자들은 QWERTY 키보드 배열을 이용한 로마자 치환(예: *tlqkf* = 씨발), 초성 전사(예: *ㅂㅅ* = 병신), 어절 내 공백 삽입(예: *씨 발*), 한영 코드스위칭과 같은 다양한 우회 전략을 구사한다. 이러한 전략들은 표준 맞춤법 기반으로 학습된 모델의 탐지를 체계적으로 무력화한다.

기존 한국어 혐오 표현 탐지 연구는 다음 세 가지 구조적 한계를 가진다. 첫째, 대부분의 선행 연구는 문제를 이진 분류(공격적/정상)로 정의하여(Moon et al., 2020; Jeong et al., 2022) 표면적 욕설(예: 피해자 진술 내 욕설), 의도적 공격성(예: 욕설 없는 위협), 집단 혐오를 구분하지 못한다. 마스킹 시스템에서 이 세 현상은 서로 다른 처리를 요구하므로 분리된 라벨 헤드가 필요하다. 둘째, 기존 모델들은 실제 우회 전략이 저평가된 정제된 벤치마크 데이터로 평가된다. 셋째, 이질적 소스로부터 구성된 학습 데이터셋은 *어노테이션 불완전성* 문제를 가진다. 예를 들어 독성과 혐오만 어노테이션된 데이터셋(K-HATERS)은 욕설에 대한 음성 신호를 제공하지 않으나, 단순 다중 태스크 학습은 어노테이션되지 않은 욕설 인스턴스를 음성 예시로 처리하여 욕설 헤드의 허위 양성 폭발을 야기한다(Lee et al., 2022).

본 연구는 이러한 한계를 극복하는 **KoHateMask** 시스템을 제안한다. 본 시스템은 크롬 익스텐션(브라우저 기반 댓글 마스킹)과 안드로이드 오버레이 앱에 실제 배포되는 프로덕션 환경 시스템으로, 세 가지 구성 요소를 포함한다: (1) 텍스트 정규화 모듈 KoNorm-v3, (2) mDeBERTa-v3-base 기반 다중 라벨 분류 모델, (3) 토큰 수준 마스킹 위치 탐지를 위한 XLM-RoBERTa-large + CRF 스펠 탐지 모델.

본 논문의 주요 기여는 다음과 같다.

- Label-mask 학습 메커니즘**: 학습 시 어노테이션되지 않은 라벨이 그래디언트에 기여하지 않도록 소스별 이진 마스크 행렬을 BCE 손실 함수에 적용하여, 호환되지 않는 어노테이션 스키마를 가진 이질적 데이터셋 간 공동 학습을 가능하게 한다.
- P/T/H 삼중 라벨 스키마**: 표면적 욕설(P), 의도적 공격성(T), 집단 혐오(H)로 구성된 세 라벨을 정의하고 H=1이면 T=1을 강제하는 온톨로지 제약을 도입한다.
- KoNorm-v3 정규화 파이프라인**: QWERTY→한글 역변환, 초성 전사, 공백 삽입 우회 병합, 변형 철자 표준화를 처리하는 한국어 특화 5단계 정규화 파이프라인을 구성한다. 외부 평가셋에서 매크로 F1 0.517 → 0.640 (+23.8%) 향상을 달성한다.
- 코드스위칭 강건성 평가**: 4가지 패턴으로 구성된 코드스위칭 테스트 스위트를 설계하고 패

턴별 매크로 F1을 보고한다. 전체 매크로 F1 0.855, QWERTY 치환 패턴에서 0.896을 달성한다.

5. **3계층 오류 분류 체계**: 모델 허위 양성(model_fp), 정책 결정 사항(policy_case), 모델 허위 음성(model_fn)으로 오류를 분류하여 모델 개선과 서비스 정책 결정 모두에 활용 가능한 진단 체계를 제안한다.
6. **플랫폼별 도메인 분석**: 인스타그램, 틱톡, 유튜브에서 수집한 실제 댓글에 대한 최초의 플랫폼 계층화 평가를 수행하여 유해 댓글 비율의 유의미한 플랫폼 간 차이(0.0%~15.8%)를 확인한다.

이하 논문의 구성은 다음과 같다. 2절에서 관련 연구를 검토하고, 3절에서 문제를 정식화하며, 4절에서 시스템 아키텍처를 기술한다. 5절에서 데이터셋 구성을 설명하고, 6절에서 통계적 유의성 검증을 포함한 실험 결과를 제시한다. 7절에서 오류 분석을 수행하고, 8절에서 스팸 탐지 성능을 분석하며, 9절에서 한계 및 향후 연구를 논의하고, 10절에서 결론을 맺는다.

2. 관련 연구

2.1 한국어 혐오 표현 탐지

한국어 혐오 표현 탐지의 초기 연구는 소셜 미디어 댓글의 이진 분류에 집중하였다. Moon et al. (2020)은 네이트 및 네이트판의 연예 뉴스 댓글 9,381건을 혐오 표현과 사회적 편향으로 수동 어노테이션한 BEEP! 코퍼스를 제안하였다. Krippendorff's alpha 약 0.49의 어노테이션 일치도를 달성하였으나, 도메인 특화성과 규모의 한계로 인해 일반 소셜 미디어의 어휘 다양성을 충분히 커버하지 못한다는 제약이 있다.

Jeong et al. (2022)은 네이버 뉴스 및 유튜브로부터 수집한 40,429건의 댓글에 대해 공격 유형, 대상 집단, 대상 텍스트 스팸을 계층적으로 어노테이션한 KOLD를 제안하였다. KOLD는 스팸 어노테이션을 제공한다는 점에서 근거 추출 연구에 특히 유용하다. Lee et al. (2022)은 한국어 온라인 뉴스 댓글 109,692건을 8가지 세분화된 혐오 범주(정치, 출신, 신체, 연령, 성별, 종교, 인종, 욕설)와 비혐오 클래스로 다중 라벨 어노테이션한 K-MHaS를 제안하였다. K-MHaS는 단일 발화가 복수의 혐오 유형을 동시에 나타내는 경우가 빈번함을 실증하였다.

KLUE 벤치마크(Park et al., 2021)는 표준화된 한국어 자연어 이해 평가 태스크와 KLUE-BERT 및 KLUE-RoBERTa 사전학습 언어 모델을 제공하여 경쟁력 있는 한국어 단일 언어 기준선을 확립하였다. 그러나 KLUE는 혐오 표현 탐지를 평가 태스크로 포함하지 않았다.

본 연구는 이질적인 한국어·영어 혐오 표현 소스 간의 공동 학습, 문자 수준 우회 전략에 대한 강건성 평가, 표준화된 F1 평가를 갖춘 한국어 스팸 탐지를 동시에 수행한 최초의 연구이다.

2.2 다국어 및 교차 언어 접근

다국어 혐오 표현 탐지의 지배적 패러다임은 대규모 사전학습 트랜스포머 모델을 활용한다. He et al. (2021)은 각 토큰의 위치와 내용을 분리하여 인코딩하는 비얽힘 어텐션(disentangled attention)을 사용한 DeBERTa를 제안하여 GLUE 및 SuperGLUE에서 최고 성능을 달성하였다. He et al. (2023)은 마스크 언어 모델링 대신 ELECTRA 방식의 대체 토큰 탐지 목적 함수와 그라디언트-비얽힘 임베딩 공유를 도입한 DeBERTaV3를 제안하였으며, large 버전은 GLUE 벤치마크에서 91.37%를 달성하였다. 본 연구는 그 다국어 base 버전인 mDeBERTa-v3-base를 분류 모델 백본으로 채택하였다.

교차 언어 전이 관점에서, Bigoulaeva et al. (2021)은 다국어 BERT를 통한 교차 언어 전이가 대상 언어의 어노테이션 데이터가 희소한 경우에도 경쟁력 있는 성능을 달성할 수 있음을 보였으나, 프로덕션 수준의 시스템에는 대상 언어 미세조정 데이터가 여전히 중요함을 강조하였다. 데이터셋

측면에서 Davidson et al. (2017)은 혐오 표현과 공격적 언어를 형식적으로 구분한 최초의 연구 중 하나로, 이 개념적 분리는 본 연구의 P/T/H 라벨 스키마의 핵심 토대를 형성한다. Founta et al. (2018)은 100,000건의 트윗에 대한 대규모 크라우드소싱 어노테이션을 수행하여 세분화된 범주에서 높은 어노테이터 간 일치도 달성의 어려움을 실증하였다.

2.3 혐오 표현 탐지에서의 코드스위칭

코드스위칭-단일 발화 내에서 두 개 이상의 언어 또는 문자 체계를 교대로 사용하는 행위-은 한국어 소셜 미디어 텍스트의 만연한 특성으로, 혐오 표현 탐지에 고유한 도전을 제기한다. 특히 QWERTY 키보드 매핑을 통한 문자 치환은 한국어 자동 탐지를 우회하는 가장 일반적인 방법이다. 한국어 자판에서 한/영 전환 없이 입력하면 한글 음소에 대응하는 라틴 문자가 출력되는 특성을 이용한다(예: *tlqkf* = 씨발).

코드스위칭 혐오 표현 탐지 연구는 주로 힌디-영어, 타밀-영어, 아랍어-영어 환경에 집중되어 있으며, 한국어-영어 혹은 한국어-QWERTY 전환에 대한 연구는 극히 부족하다. Samghabadi et al. (2020)은 문자 수준 특징이 코드스위칭 및 로마자화 텍스트에 의한 성능 저하를 실질적으로 완화함을 보였다. 한국어의 경우, QWERTY 매핑 기반 코드스위칭은 결정론적 역변환 규칙을 적용할 수 있어 정확하면서도 계산 비용이 낮은 복원이 가능하며, 이 특성을 KoNorm-v3에서 활용하였다. Rizos et al. (2019)은 혐오 표현 클래스에 대한 표적 데이터 증강이 매크로 F1에서 절대적 5.7%p 향상을 가져옴을 입증하여, 본 연구의 합성 데이터 증강 전략을 지지한다.

2.4 스패ن 탐지 및 근거 추출

문서 수준 분류를 넘어 어떤 토큰이 혐오 표현을 구성하는지 식별하는 것은 세밀한 마스킹 시스템에 필수적이다. DeYoung et al. (2020)은 ERASER 벤치마크를 통해 다양한 NLP 태스크에 걸친 근거 추출 평가를 체계화하였으며, 높은 분류 정확도를 달성하는 모델이 반드시 충실하거나 타당한 근거를 생성하지는 않음을 보였다. Mathew et al. (2021)은 HateXplain에서 인간 어노테이션 근거 스패스로 학습된 모델이 대상 집단에 대한 의도하지 않은 편향을 감소시킴을 보여, 해석 가능성과 공정성 간의 연결고리를 확립하였다.

CRF 디코딩을 활용한 토큰 분류(Lafferty et al., 2001)는 한국어 NLP의 시퀀스 레이블링에서 표준적 접근법으로 자리잡았다(Park et al., 2021). XLM-RoBERTa(Conneau et al., 2020)는 BIO 태깅을 위한 강력한 다국어 토큰 표현을 제공한다. KOLD(Jeong et al., 2022)는 어노테이션된 공격성 스패ンを 제공하는 유일한 대규모 한국어 데이터셋으로, 본 연구의 스패น 탐지 모듈 학습의 주요 신호원으로 활용된다.

2.5 데이터셋 구성 및 라벨 품질

다중 소스 혐오 표현 학습 코퍼스 구성은 라벨 일관성과 완전성에 관한 비자명한 문제를 제기한다. 핵심 문제는 단순한 라벨 노이즈가 아니라 구조적 라벨 불완전성이다: 성별 기반 혐오만 어노테이션된 데이터셋은 욕설과 일반 독성을 미어노테이션 상태로 남기므로, 비어노테이션 라벨을 음성으로 처리하면 학습 중 체계적 허위 음성이 발생한다.

어노테이터 불일치와 라벨 이질성 문제는 광범위하게 문서화되었다. Founta et al. (2018)은 언어적 학대가 연속적 스펙트럼에서 나타나 날카로운 범주 경계가 본질적으로 주관적임을 관찰하였다. APEACH 벤치마크(Yang et al., 2022)는 학습과 평가 코퍼스 간의 도메인 중복을 최소화하기 위해 크라우드소싱 도출 방식으로 평가 예시를 생성하였으며, 이 설계 원칙이 본 연구의 외부 평가 프로토콜에 반영되었다.

본 연구에서 도입하는 label-mask 메커니즘은 개념적으로 부분 라벨 학습(Cour et al., 2011) 및 노이즈 라벨 학습(Natarajan et al., 2013)과 관련되나, 불완전성이 무작위가 아닌 데이터셋 소스에 종속된 체계적 불완전성이라는 점에서 다르다. 인스턴스 수준의 부분 라벨 방법과 달리, label-mask는 데이터셋 소스 수준에서 적용되며 BCE 손실 계산에 직접 통합되어 모델 아키텍처 수정을

요구하지 않는다.

3. 문제 정형화

표기 정의. $\mathcal{X}$ 를 한국어/영어 텍스트 시퀀스 공간, $\mathcal{Y}=\{0,1\}^3$ 을 다중 라벨 출력 공간이라 하자. 각 학습 인스턴스 $(x, \mathbf{y}, \mathbf{m}) \in \mathcal{X} \times \mathcal{Y} \times \{0,1\}^3$ 은 텍스트 x , 라벨 벡터 $\mathbf{y}=(y_P, y_T, y_H)$, 어노테이션 마스크 $\mathbf{m}=(m_P, m_T, m_H)$ 로 구성된다. 마스크 값 $m_i=0$ 은 해당 인스턴스에서 i 번째 라벨이 어노테이션되지 않았음을 의미한다.

라벨 정의:

- **욕설 P (Profanity):** 정규화된 텍스트에 표면적 욕설 또는 비속어 어휘가 존재하는가 (표면 수준)
- **공격성 T (Toxicity):** 발화가 대상에 대해 공격적, 모욕적, 위협적, 비하적 의도를 표현하는가 (의도 수준)
- **혐오 H (Hate):** 발화가 성별, 인종, 종교, 성적 지향, 장애, 연령, 사회경제적 계층 등 보호집단을 비인간화하거나 차별하는가 (집단 수준)
- **제약 조건:** $H=1 \Rightarrow T=1$ (추론 시 강제 적용)

학습 목표는 분류 함수 $f: \mathcal{X} \rightarrow [0,1]^3$ 을 학습하여 $f(x)_i \geq \tau_i$ 이면 $y_i=1$ 이 되도록 하는 것이다. 여기서 $\tau_i \in [0,1]$ 은 검증셋에서 최적화된 라벨별 결정 임계값이다.

Label-mask 학습 목적함수. 라벨 스무딩 파라미터 ϵ 을 적용한 마스크 BCE 손실은 다음과 같다:

$$\mathcal{L}(\theta) = -\frac{1}{|\mathcal{B}|} \sum_{(x, \mathbf{y}, \mathbf{m}) \in \mathcal{B}} \sum_{i \in \{P, T, H\}} \frac{m_i}{\sum_j m_j} \cdot w_i \cdot \text{BCE}(\hat{y}_i, \tilde{y}_i)$$

여기서 각 항은 다음과 같이 정의된다:

기호	정의
$\tilde{y}_i$	라벨 스무딩 목표값: $y_i(1-\epsilon) + 0.5\epsilon$
w_i	클래스 불균형 가중치: $\sqrt{N_{\text{neg}}/N_{\text{pos},i}}$, 범위 [1, 20]으로 클리핑
$m_i/\sum m_j$	유효 라벨 수에 따라 손실을 정규화하는 항 ($m_i=0$ 인 쌍은 손실 기여 0)
$\mathcal{B}$	미니배치

핵심 메커니즘: $m_i=0$ 인 (소스, 라벨) 쌍은 손실 기여분이 0이 되어 역전파에서 제외된다. 정규화 항 $m_i/\sum m_j$ 은 유효 라벨 수에 따라 샘플별 손실을 스케일링하여, 일부 라벨만 어노테이션된 샘플이 완전 어노테이션 샘플과 동일한 가중치를 갖지 않도록 조정한다. 이를 통해 욕설을 어노테이션하지 않은 데이터셋(K-HATERS, KOLD 등)의 비어노테이션 욕설 인스턴스가 욕설 헤드 학습에서 허위 음성 신호로 작용하는 것을 방지한다.

4. 시스템 아키텍처

4.1 KoNorm-v3: 텍스트 정규화 파이프라인

KoNorm-v3는 원시 입력 텍스트에 다음 5단계 변환을 순차 적용한다.

1단계 - 기준 정규화: 제로 너비 문자, 동형 이의어(homoglyph), 제어 코드 제거. *inko* 라이브러리를 통한 QWERTY→한글 역변환. 유니코드 NFC 정규화. 이모지, 가타카나, 장식적 기호 삽입 제거. 반복 문자 축약(예: ㅋㅋㅋㅋ → ㅋ). 초성 시퀀스 음소 조립. 선행행 공백 정규화.

2단계 - 공백 삽입 우회 병합: 어절 내 공백 삽입을 통해 탐지를 우회하는 전략에 대응한다(예: 씨발 → 씨발). 말뭉치 분석을 통해 확인된 7가지 고빈도 패턴(개새끼, 씨발, 새끼, 병신, 미친, 지랄, 존나)에 대해 표적 병합 규칙을 적용한다.

3단계 - 복합 초성 자모 확장: 복합 자모 문자 ㅃ (U+3144)를 가장 가능성 높은 해석인 '병신'으로 확장한다. 이는 1단계의 두 글자 초성 처리를 보완한다.

4단계 - QWERTY 욕설 직접 치환: *inko* 라이브러리 설치 여부와 무관하게 동작하는 fallback 치환 규칙을 8가지 패턴에 적용한다(rotorrl→개새끼, tlqkfwk→시발아, tlqkf→시발, qudtls→병신, wlfkf→지랄, alcls→미친, rjwu→거져[꺼져 소문자 근사], ehfkdl→도라이). 쌍자음(ㄲ, ㅈ 등)이 관련된 패턴은 대소문자 무관 처리로 단자음 근사형을 포함한다.

5단계 - 형태소 변형 정규화: 말뭉치 EDA에서 확인된 변형 비율 50배 이상의 23가지 고빈도 철자 변형을 표준형으로 매핑한다(예: 씨빨→씨발, 썬발→씨발, 새끼→새끼).

4.2 다중 라벨 분류 모델

인코더: `microsoft/mdeberta-v3-base` (파라미터 수: 183M)를 사용한다. 콘텐츠와 상대적 위치 인코딩에 대한 비어힘 셀프 어텐션을 채택하며, 대체 토큰 탐지(ELECTRA 목적함수)로 100개 언어의 CC-100 및 Wikipedia/BookCorpus에 사전학습되었다.

풀링: 어텐션 마스크로 패딩을 제거한 모든 토큰 표현에 대한 평균 풀링.

분류 헤드: 2-레이어 MLP - Linear(H→H) → GELU → Dropout(0.1) → Linear(H→3). H=768은 은닉 차원.

학습 설정: - 최적화: AdamW, 인코더 학습률 2e-5, 헤드 학습률 1e-4, 가중치 감쇠 0.01 - 스케줄: 전체 스텝의 10%에 대한 선형 웜업 - 배치 크기: 32; 그래디언트 클리핑 1.0; 혼합 정밀도 (FP16) - 라벨 스무딩: $\epsilon=0.05$; 최대 시퀀스 길이: 160 토큰; 학습 에폭: 5 - 최적 체크포인트: 검증 셋 매크로 F1 기준

라벨별 임계값 교정: 각 에폭마다 검증셋에서 $\{\tau_P, \tau_T, \tau_H\}$ 를 0.02 간격 그리드 탐색으로 독립적으로 최적화한다.

4.3 스파ن 탐지 모듈

토큰 수준 공격성 스파ن 위치 탐지를 위해 XLM-RoBERTa-large (파라미터 수: 560M)를 인코더로, BIO 태깅(O, B-OFF, I-OFF)을 위한 선형 CRF 헤드를 사용한다.

학습: KOLD와 K-HATERS BIO 어노테이션으로부터 203,800개 샘플. 가중치 샘플링(스팬 포함 샘플 2배, KOLD 소스 2배)으로 K-HATERS 지배를 보정. `use_for_span=False` 표시 샘플은 BIO 손실 마스킹 적용.

후처리: (1) 인접 스파ن 병합: 3글자 이내 거리의 스파ンを 먼저 병합한다. (2) 단어 제거: 화이트리스트 토큰(씨앗, 존버, 시발점 등) 및 CRF 방출 신뢰도 0.5 미만 스파ンを 제거한다. 병합을 선행하여 씨발 등 공백 삽입 분할 스파ん이 제거 전 결합될 수 있도록 한다. 단, 1음절(2바이트 미만) 독립 스파ん은 탐지 모델에 위임하며 후처리에서 별도 제거하지 않는다.

파이프라인 통합: 분류 모델이 offensive로 판정한 발화에 대해서만 스파ん 탐지 실행. 스파ん 미탐지 시 발화 전체 마스킹으로 풀백.

5. 데이터셋 구성

5.1 학습 데이터

소스	언어	행수	P	T	H	비고
K-HATERS	한	172,120	0	1	1	SNS 댓글; P 미어노테이션
K-MHaS	한	78,552	1	1	1	트위터; 다중 라벨
Jigsaw Toxic (재라벨)	영	73,650	1	0	1	Wikipedia 편집; T 마스킹 (도메인 이질)
Civil Comments	영	46,902	0	1	1	뉴스 댓글; P 미어노테이션
KOLD	한	31,598	0	1	1	뉴스 댓글; P 미어노테이션
UnSmile	한	14,987	1	1	1	카카오; 균형 구성
NSMC (재라벨)	한	7,929	1	1	1	영화 리뷰; Claude 재라벨
KorHate (재라벨)	한	4,060	1	1	1	경계 사례; Claude 재라벨
하드 네거티브	한	998	1	1	1	합성; 차별금지법 FP 억제
합성 욕설	한	990	1	1	1	합성; 우회 변형 욕설 학습
합계		431,786				

Jigsaw Toxic 재라벨 근거: 탐색적 데이터 분석 결과, Wikipedia 토론 편집 페이지 기반의 Jigsaw Toxic 데이터셋은 한국어 소셜 미디어 데이터(9.6%)에 비해 도메인 특화적 공격성 비율(18.2%)이 과대계상됨이 확인되었다. T 라벨을 마스킹(label_mask=[1,0,1])함으로써 도메인 이질적 공격성 신호가 한국어 공격성 헤드를 오염시키는 것을 방지한다.

하드 네거티브 구성: v2 모델에서 전체 허위 양성의 83.7%를 차지하는 차별금지법·성소수자 관련 정상 발화에 대한 토픽 수준 허위 양성 편향을 완화하기 위해, 민감한 토픽 키워드를 포함하는 정상 발화 998건을 대형 언어 모델(LLM)을 이용해 생성하고 수작업 검토하였다.

5.2 검증 및 테스트 분할

검증셋: 모든 소스에서 비례 추출한 74,808개 샘플. 임계값 교정 및 조기 종료에 사용.

내부 테스트셋: 36,358개 샘플(학습 데이터와 동일 분포). 욕설은 label_mask[P]=1인 23,139개 샘플에서만 평가.

외부 테스트셋 (APEACH + HateXplain): 학습 중 전혀 노출되지 않은 독립 데이터셋 2개로부터 30,895개 샘플 구성. 1차 일반화 성능 벤치마크로 활용.

코드스위칭 스트레스 테스트: 4가지 우회 함수를 선별된 공격적/정상 시드 텍스트에 프로그래밍 방식으로 적용하여 생성한 1,000개 합성 샘플.

6. 실험

6.1 실험 설정

모든 모델은 단일 NVIDIA GPU에서 학습되었다(CUDA 환경). 에폭당 학습 시간은 약 11,650_{11,842초}($\approx 3.23.3$ 시간)로, 총 학습 예산은 약 16.5 GPU-시간이다. 검증셋 매크로 F1 기준 최적 에폭(에폭 4, F1=0.7555) 체크포인트에서의 결과를 보고한다.

비교 기준 모델: - **v2 기준선**: 동일한 mDeBERTa-v3-base 백본, label_mask 미적용, 데이터셋 조건화 임베딩 포함(허위 양성 폭발 야기 구성). - **v3 (제안 모델)**: 본 논문에서 기술한 전체 시스템.

6.2 주요 결과

표 1. v3 내부 테스트셋 성능 (36,358개 샘플)

라벨	정밀도	재현율	F1	95% 신뢰구간
욕설(P)	0.522	0.806	0.634	[0.615, 0.652]
공격성(T)	0.831	0.879	0.854	[0.851, 0.858]
혐오(H)	0.780	0.841	0.810	[0.805, 0.815]
매크로	0.711	0.842	0.766	[0.760, 0.773]

신뢰구간: 층화 부트스트랩 ($n=5,000$, $seed=42$). 욕설은 어노테이션 감독 23,139개 샘플에서 평가.

표 2. 외부 일반화 성능 (APEACH + HateXplain, 30,895개 샘플)

모델	공격성 F1	혐오 F1	매크로 F1 (T+H)	변화량
v2 (기준선)	0.588	0.447	0.517	—
v3 (제안)	0.718	0.562	0.640	+ 0.123 (+ 23.8%)

APEACH+HateXplain은 욕설 어노테이션을 제공하지 않아($support=0$) 욕설은 T+H 비교에서 제외.

6.3 학습 곡선

에폭	학습 손실	검증 매크로 F1	임계값 [P, T, H]
1	0.627	0.729	[0.80, 0.28, 0.62]
2	0.544	0.742	[0.78, 0.50, 0.72]
3	0.507	0.752	[0.78, 0.50, 0.76]
4	0.475	0.7555 ★	[0.74, 0.56, 0.66]
5	0.448	0.7536	[0.80, 0.46, 0.68]

학습 손실은 전체 5에폭에 걸쳐 단조 감소하는 반면, 검증 매크로 F1은 에폭 4(0.7555)에서 최고점에 도달한 후 에폭 5(0.7536)에서 소폭 하락하여 경미한 과적합을 나타낸다. 최적 모델은 에폭 4에서 저장된다.

6.4 코드스위칭 강건성

표 3. 코드스위칭 스트레스 테스트 (1,000개 샘플, 4가지 패턴)

패턴	예시	욕설 F1	공격성 F1	혐오 F1	매크로 F1
intra_word_mix	씨/bal눔	0.766	0.961	0.851	0.859
inter_word_insert	야 fuck 병신야	0.756	0.982	0.888	0.875
qwerty_leak	tlqkf 진짜	0.805	0.995	0.886	0.896
inter_word_swap	야 bastard야	0.724	0.958	0.875	0.852
전체	—	0.725	0.968	0.873	0.855

전체 행은 4패턴 F1의 단순 평균이 아니라 1,000개 샘플 통합 평가 결과임.

qwerty_leak 패턴이 매크로 F1 0.896으로 최고 성능을 보인다. KoNorm-v3의 QWERTY→한글 역변환이 분류 전 표준 한국어 표면형을 효과적으로 복원함을 확인한다. 공격성 F1이 모든 패턴에서 일관되게 높은(0.958~0.995) 반면 욕설 F1은 상대적으로 낮은(0.724~0.805) 이유는, 공격성이 주로 맥락 의존적인 데 비해 욕설이 어휘 앵커에 의존하기 때문이다.

6.5 플랫폼별 도메인 분석

인스타그램, 틱톡, 유튜브 세 플랫폼에서 수집한 실제 SNS 댓글 136건을 v3 모델로 평가하였다.

표 4. 플랫폼별 분석 (실제 SNS 댓글, v3 모델)

플랫폼	n	유해	욕설	공격	혐오	유해 비율	평균 P	평균 T	평균 H
인스타그램	24	0	0	0	0	0.0%	0.151	0.043	0.069
틱톡	93	1	1	1	0	1.1%	0.151	0.044	0.075
유튜브	19	3	0	3	2	15.8%	0.210	0.217	0.169

유튜브가 15.8%로 현저히 높은 유해 댓글 비율을 보이는 반면, 틱톡(1.1%)과 인스타그램(0.0%)은 낮은 수준을 나타낸다. 이는 플랫폼 수준의 콘텐츠 거버넌스 차이를 반영한다: 인스타그램의 키워드 기반 필터링이 가장 노골적인 표현을 사전 차단하는 반면, 유튜브는 정치적·사회적으로 논쟁적인 콘텐츠에 대한 사전 필터링이 상대적으로 약하다. 유튜브 위반의 대부분이 공격성 및 혐오(각 3건, 2건)이며 욕설이 0건인 점은, 정치 성향 콘텐츠에서 표면 욕설 없는 집단 혐오가 더 일반적임을 시사한다.

주의: 특히 유튜브(n=19)의 샘플 크기가 작아 통계적 대표성보다는 방향성 지표로 해석해야 한다. 플랫폼별 신뢰성 있는 비교를 위한 대규모 수집 연구가 필요하다.

6.6 통계적 유의성

모든 F1 신뢰구간은 비모수 총화 부트스트랩 (n=5,000, 랜덤 시드=42)으로 산출한다. 이진 예측 벡터는 정밀도, 재현율, support 통계로부터 대수 관계 $TP = Recall \times support$ 를 이용하여 근사 복원한다. 이 방식은 원시 예측 쌍을 직접 리샘플링하는 표준 bootstrap과 달리 요약 통계로부터 복원된 근사 벡터를 사용하므로, 보고된 CI는 참조 수준의 신뢰구간으로 해석해야 한다.

공격성 [0.851, 0.858]과 욕설 [0.615, 0.652]의 95% 신뢰구간이 겹치지 않아 두 라벨 간 성능 차이가 통계적으로 유의미함을 확인한다 ($p < 0.001$, 부트스트랩 검정). 매크로 F1 신뢰구간 [0.760, 0.773]은 대규모 테스트셋(n=36,358)을 반영하여 상당히 좁다.

외부 APEACH+HateXplain 비교에서, v2 매크로 F1=0.517에서 v3 매크로 F1=0.640으로의 향상

(+0.123)은 맥네마 검정을 통해 통계적으로 유의미함이 확인된다 ($\chi^2=342.1$, $p<0.001$).

7. 오류 분석

7.1 오류 분류 체계

ground-truth 라벨과 판정 분류를 갖춘 32개 케이스 어노테이션 테스트셋에 3계층 오류 분류 체계를 적용한다.

계층 A – 모델 허위 양성 (개선 가능): 표면 욕설이 없고 실제 정상 텍스트인데 모델이 offensive로 예측. 주원인은 학습 데이터의 토픽 수준 편향이다.

계층 B – 정책 결정 사항 (편집 정책 필요): 텍스트에 표면 욕설이 존재하나 의사소통 기능은 무해하다(인용/보고 발화, 교육적 열거, 긍정 레지스터 비속어). 욕설 라벨 정의(표면 수준)상 모델의 탐지는 기술적으로 정확하나, 적절한 마스킹 여부는 배포 맥락에 따라 결정된다.

계층 C – 모델 허위 음성 (개선 가능): 실제로 offensive이나 모델이 탐지 실패. 주원인은 표면 욕설 마커 없는 간접적·완곡적 혐오 표현이다.

표 5. v3 오류 분류 결과 (32개 확장 테스트셋)

계층	건수	설명	v3 결과
A (모델 허위 양성)	0건	실제 정상, 오류 탐지	v2 대비 72건 → 0건 (차별금지법 토픽 편향 완전 해소)
B (정책 결정 사항)	6건	표면 욕설 있음, 무해 맥락	인용 발화, 긍정 비속어, 의학 용어 등
C (모델 허위 음성)	4건	실제 offensive, 미탐지	초성 우회, 암묵적 차별 등
TP (정상 탐지)	11건	offensive 올바른 탐지	
TN (정상 통과)	11건	정상 올바른 통과	

가장 주목할 결과는 계층 A 허위 양성의 완전 제거이다. v2는 차별금지법·성소수자 관련 정상 발화에 대해 72건의 허위 양성을 발생시켰으며 (전체 허위 양성의 83.7%), v3에서 하드 네거티브 증강으로 이를 완전히 해소하였다. 공격성 점수가 ~0.91에서 <0.10으로 급감하였다.

7.2 정책 결정 필요 사례

6개 정책 결정 사례는 서비스 정책의 명시적 결정을 필요로 한다:

사례	예시	P 점수	서비스 정책 고려 사항
피해자 진술	“그 사람이 나한테 병신이라고 했어”	0.986	마스크 시 피해자의 신고 능력 훼손
뉴스 인용	“피의자는 피해자에게 ‘이 병신 새끼야’라고...”	0.982	마스크 시 언론 보도 정확성 저해
교육적 나열	“대표적 비속어로는 병신, 새끼 등이 있습니다”	0.885	마스크 시 교육·언어 콘텐츠 훼손
긍정 강조어	“존나 잘생겼다 이 배우”	0.995	한국어 일상 담화에서 광범위하게 사용
긍정 감탄	“미쳤다 이 노래 진짜 개쩐다”	0.939	구어체 열광 표현
의학 용어	“항문암 조기 발견이 치료율을 높입니다”	T=0.747, H=0.898	해부학적 의학 용어를 혐오로 오인

의학 용어 사례(“항문암”)는 v3에서도 잔존하는 모델 허위 양성으로, 해부학 용어 “항문”이 T=0.747, H=0.898의 높은 점수를 야기한다. 이는 현재 모델의 표면형 패턴 연관 학습의 한계를 드러낸다.

7.3 스코어 프로파일 분석

그림 K에서 오류 유형별 일관된 패턴이 나타난다: (1) 정상 탐지(TP)는 관련 라벨 전반에서 높은 점수를 보이고 (P=0.55, T=0.89, H=0.57); (2) 정책 결정 사항은 높은 욕설 점수(P=0.82)와 낮은 공격성(T=0.48)으로 군집화되어 표면 욕설은 있으나 공격적 의도는 없음을 반영한다; (3) 모델 허위 음성은 세 라벨 모두에서 낮은 점수를 나타내어(P=0.18, T=0.28, H=0.13), 임계값 조정이 아닌 아키텍처 개선이 필요한 사례임을 시사한다.

7.4 잔존 허위 음성 분석

확장 테스트셋의 4개 잔존 모델 허위 음성은 질적으로 구분되는 실패 유형을 나타낸다:

- 초성 우회 (ㅎㄷ 대박 짜증):** 정규화기가 ㅎㄷ를 비단어 형태로 잘못 조립하여 의도된 욕설 복원 실패. 이는 분류기가 아닌 정규화기의 실패이다.
- 경계선 암묵적 차별 (노숙자들이 거리 분위기 망치네):** 공격성 점수=0.517, 임계값=0.56 - 여유분 0.04. 임계값 소폭 하향이 이를 정상 탐지로 전환하겠으나, 다른 부분에서의 허위 양성 증가를 수반한다.
- 학술 레지스터 차별 (명문대 출신들만 뽑으면 되는데):** 세 라벨 모두 0.14 미만. 표면 욕설이 없으며 차별 의도가 고도로 암묵적으로 표현되어 한국 교육 능력주의에 대한 더 넓은 사회적 맥락을 요구한다.
- 맥락 없는 외국인 혐오 (그냥 저 나라 사람들은 원래 저래):** 세 라벨 모두 0.19 미만. “저 나라”의 명확한 지시 대상이 없어 모델이 외국인 혐오 의도를 추론할 수 없다 - 맥락 없는 문장 수준 분류의 근본적 한계이다.

8. 스패 탐지 성능

스패 탐지 모듈(XLM-RoBERTa-large + CRF)은 검증셋($n=13,954$)에서 스패 수준 F1 0.554 ($P=0.579$, $R=0.512$)를 달성한다.

표 6. 스패 탐지 결과

수준	정밀도	재현율	F1
토큰 수준 (검증)	0.779	0.530	0.631
스패 수준 (검증 최적)	0.579	0.512	0.554

정밀도가 재현율을 상회하여($0.579 > 0.512$), 탐지된 스패는 비교적 정확하지만 약 절반의 공격성 스패를 놓친다. 추론 출력 분석에서 세 가지 실패 유형이 확인된다: (1) *부분 스패 탐지* - 다단어 공격성 구절의 일부만 태깅(예: “개새끼” → “새끼 꺼져”); (2) *집단명 누락* - 집단을 향한 혐오 표현에서 집단명이 스패에 미포함(예: “동성애자들은 전부 병자야” → “전부 병자”만 태깅); (3) *암묵적 혐오의 스패 부재* - 맥락적 추론으로 offensive 판정되었으나 표면 혐오 마커가 없는 발화에서 스패 없음 → 전체 문장 마스킹 폴백.

9. 한계 및 향후 연구

절제 실험 미수행: 각 학습 구성 요소(label_mask, 하드 네거티브, 정규화기 단계, jigsaw 재라벨)의 개별 기여도를 정량화하는 통제된 절제 실험을 수행하지 않았다. 전체 절제는 추가 6회 학습 실험(≈ 100 GPU-시간)이 필요하며, 이를 향후 과제로 남긴다.

기준 모델 비교 제한: 자원 제약으로 인해 KcBERT(Lee, 2020), KoELECTRA(Park et al., 2020), KLUE-RoBERTa(Park et al., 2021)와의 동일 테스트셋 직접 비교를 수행하지 않았다. mDeBERTa-v3-base가 교차 언어 태스크에서 이러한 한국어 단일 언어 모델을 일반적으로 능가함을 감안할 때 성능 우위가 유지될 것으로 예상되나, 직접 검증은 향후 연구로 남긴다.

커뮤니티 특화 어휘 부족: 일베, 디시인사이드, 급진적 페미니즘 커뮤니티의 특화 은어(홍어, 톨딱, 한남충, 맘충 등)에 대해 모델이 학습되지 않았다. K-HATERS가 부분적 커버리지를 가질 수 있으나 이 범주에 대한 체계적 평가는 수행되지 않았다.

어노테이터 간 일치도 미측정: 골드 테스트셋(500건, kor_hate_relabeled 파생)은 단일 어노테이터(인간 검토를 거친 Claude claude-sonnet-4-6)가 라벨링하였다. Cohen's κ 가 측정되지 않아 이 분할에서의 라벨 신뢰도 주장이 약화된다.

도메인 이동: 플랫폼별 분석은 19개 수집 파일의 136건 댓글로 수행된 소규모 파일럿 연구이다. 통계적으로 신뢰할 수 있는 플랫폼 비교를 위해서는 플랫폼별 10,000건 이상의 수동 어노테이션이 필요하다.

향후 연구 방향: - 통제된 절제 실험을 통한 각 구성 요소 기여도 정량화 - BEEP! 코퍼스 통합 (+9,381건) - 커뮤니티 은어 합성 데이터 추가 (+500건: 일베/디시 은어) - 정책 결정 사항에 대한 인간 평가 ($N=20$ 어노테이터) - 혐오 대상 분류 헤드 추가를 통한 멀티태스크 학습 탐색 - 의료·법률 도메인 허위 양성 완화

10. 결론

본 논문에서는 한국어 혐오 표현 탐지 및 마스킹 시스템 KoHateMask를 제안하였다. 세 라벨(욕설

·공격성·혐오)에 대해 36,358개 샘플 테스트셋에서 매크로 F1 0.766 [95% CI: 0.760-0.773]을 달성한다. 핵심 기술 기여는 다음과 같다: (1) 어노테이션 스키마가 호환되지 않는 이질적 데이터셋들 간의 공동 학습을 가능하게 하는 label-mask 학습 메커니즘; (2) 코드스위칭 스트레스 테스트에서 매크로 F1 0.855를 달성하는 KoNorm-v3 5단계 정규화 파이프라인; (3) 회피 가능한 모델 오류와 정책 결정이 필요한 탐지 사례를 구분하는 3계층 오류 분류 체계.

label-mask 메커니즘은 v2 기준선에서 욕설 허위 양성 폭발을 야기한 허위 음성 그래디언트 문제를 해소하며, 하드 네거티브 증강은 v2 기준 86건 모델 오류 허위 양성 전체의 원인인 차별금지법·성소수자 관련 담화에서의 토픽 수준 편향을 완전히 해소한다. 외부 APEACH+HateXplain 벤치마크에서 v2 대비 매크로 F1 23.8% 상대적 향상을 달성한다.

실제 SNS 댓글에 대한 플랫폼별 분석은 유해 콘텐츠 비율에서 유의미한 도메인 변이를 밝혀낸다: 유튜브 15.8%, 틱톡 1.1%, 인스타그램 0.0%로, 플랫폼 적응형 임계값 조정의 필요성을 시사한다.

참고 문헌

- [1] T. Davidson, D. Warmusley, M. Macy, and I. Weber, "Automated hate speech detection and the problem of offensive language," in *Proc. 11th Int. AAAI Conf. Web and Social Media (ICWSM)*, 2017, pp. 512-515.
- [2] J. DeYoung, S. Jain, N. F. Rajani, E. Lehman, C. Xiong, R. Socher, and B. C. Wallace, "ERASER: A benchmark to evaluate rationalized NLP models," in *Proc. 58th Annu. Meeting Assoc. Comput. Linguistics (ACL)*, 2020, pp. 4443-4458.
- [3] A.-M. Founta et al., "Large scale crowdsourcing and characterization of Twitter abusive behavior," in *Proc. 12th Int. AAAI Conf. Web and Social Media (ICWSM)*, 2018, pp. 491-500.
- [4] P. He, X. Liu, J. Gao, and W. Chen, "DeBERTa: Decoding-enhanced BERT with disentangled attention," in *Proc. 9th Int. Conf. Learning Representations (ICLR)*, 2021.
- [5] P. He, J. Gao, and W. Chen, "DeBERTaV3: Improving DeBERTa using ELECTRA-style pre-training with gradient-disentangled embedding sharing," in *Proc. 11th Int. Conf. Learning Representations (ICLR)*, 2023.
- [6] Jigsaw/Conversation AI, "Civil Comments Dataset," 2019. [Online]. Available: <https://www.kaggle.com/c/jigsaw-unintended-bias-in-toxicity-classification>
- [7] Y. Jeong et al., "KOLD: Korean offensive language dataset," in *Proc. 2022 Conf. Empirical Methods in Natural Language Processing (EMNLP)*, 2022, pp. 10879-10894.
- [8] J. Lee, S. Lim, H. Lee, and A. Oh, "K-MHaS: A multi-label hate speech detection dataset in Korean online news comment," in *Proc. 29th Int. Conf. Computational Linguistics (COLING)*, 2022, pp. 3530-3538.
- [9] B. Mathew et al., "HateXplain: A benchmark dataset for explainable hate speech detection," in *Proc. 35th AAAI Conf. Artificial Intelligence*, 2021, pp. 14867-14875.
- [10] I. Mollas et al., "ETHOS: A multi-label hate speech detection dataset," *Complex & Intelligent Systems*, vol. 8, no. 6, pp. 4663-4678, 2022.
- [11] J. Moon, W.-I. Cho, and J. Lee, "BEEP! Korean corpus of online news comments for toxic speech detection," in *Proc. 8th Int. Workshop Natural Language Processing for Social Media (SocialNLP)*, 2020, pp. 25-31.

- [12] S. Park et al., "KLUE: Korean language understanding evaluation," in *Proc. 35th Conf. Neural Information Processing Systems (NeurIPS), Datasets and Benchmarks Track*, 2021.
- [13] G. Rizos, K. Hemker, and B. Schuller, "Augment to prevent: Short-text data augmentation in deep learning for hate-speech classification," in *Proc. 28th ACM Int. Conf. Information and Knowledge Management (CIKM)*, 2019, pp. 2775–2783.
- [14] K. Yang, W. Jang, and W.-I. Cho, "APEACH: Attacking pejorative expressions with analysis on crowd-generated hate speech evaluation datasets," in *Findings of Assoc. Comput. Linguistics: EMNLP*, 2022, pp. 7177–7184.
- [15] A. Conneau et al., "Unsupervised cross-lingual representation learning at scale," in *Proc. 58th Annu. Meeting Assoc. Comput. Linguistics (ACL)*, 2020, pp. 8440–8451.
- [16] J. Lafferty, A. McCallum, and F. C. Pereira, "Conditional random fields: Probabilistic models for segmenting and labeling sequence data," in *Proc. 18th Int. Conf. Machine Learning (ICML)*, 2001, pp. 282–289.
- [17] T. Cour, B. Sapp, and B. Taskar, "Learning from partial labels," *Journal of Machine Learning Research*, vol. 12, pp. 1501–1536, 2011.
- [18] N. Natarajan, I. S. Dhillon, P. Ravikumar, and A. Tewari, "Learning with noisy labels," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 26, 2013, pp. 1196–1204.
- [19] I. Bigoulaeva, V. Hangya, and A. Fraser, "Cross-lingual transfer learning for hate speech detection," in *Proc. 1st Workshop on Language Technology for Equality, Diversity and Inclusion (LT-EDI)*, EACL, 2021, pp. 15–25.
- [20] D. Borkan, L. Dixon, J. Sorensen, N. Thain, and L. Vasserman, "Nuanced metrics for measuring unintended bias with real data for text classification," in *Companion Proc. Web Conference 2019*, 2019, pp. 491–500.
- [21] Z. Waseem and D. Hovy, "Hateful symbols or hateful people? Predictive features for hate speech detection on Twitter," in *Proc. NAACL-HLT 2016 Student Research Workshop*, 2016, pp. 88–93.
- [22] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "BERT: Pre-training of deep bidirectional transformers for language understanding," in *Proc. 2019 Conf. NAACL-HLT*, 2019, pp. 4171–4186.
- [23] L. Stappen, A. Baird, G. Lux, E. Cambria, Y. Zheng, and B. Schuller, "Cross-lingual zero- and few-shot hate speech detection utilising frozen transformer language models and AXEL," *arXiv:2012.09364*, 2020.